MUBD

Màster Universitari en Enginyeria de Dades Massives (Big Data)

Estadística

laSalle ENG
Universitat Ramon Llull

Índice

Regresión lineal

01 Introducción al modelo lineal

02 Fases de estimación del modelo

1. Formulación
2. Estimación de los parámetros
3. Interpretación de los coeficientes
4. Selección de variables
   a. Colinealidad
   b. Bondad de Ajuste
5. Validación de las premisas

03 Predicción

04 Evaluación

Inferencia Estadística

Introducción al modelo lineal

01

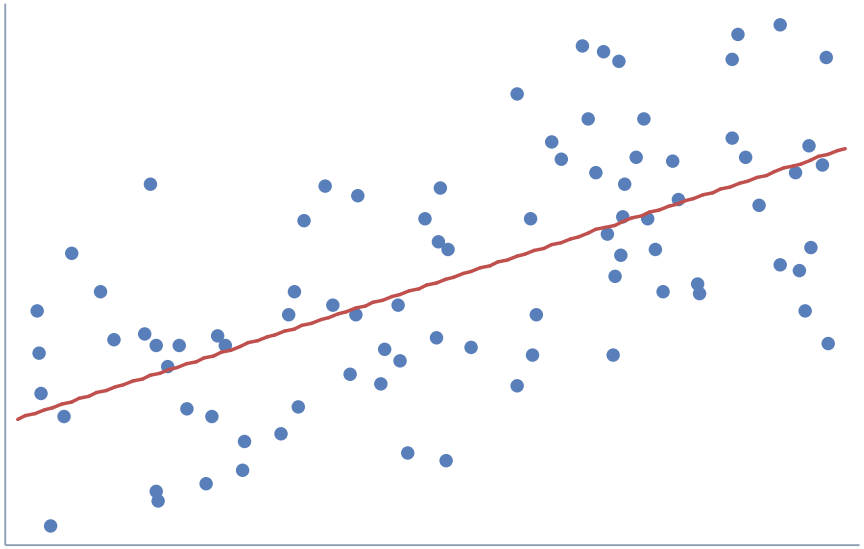
laSalle ENG
Universitat Ramon Llull

El modelo lineal

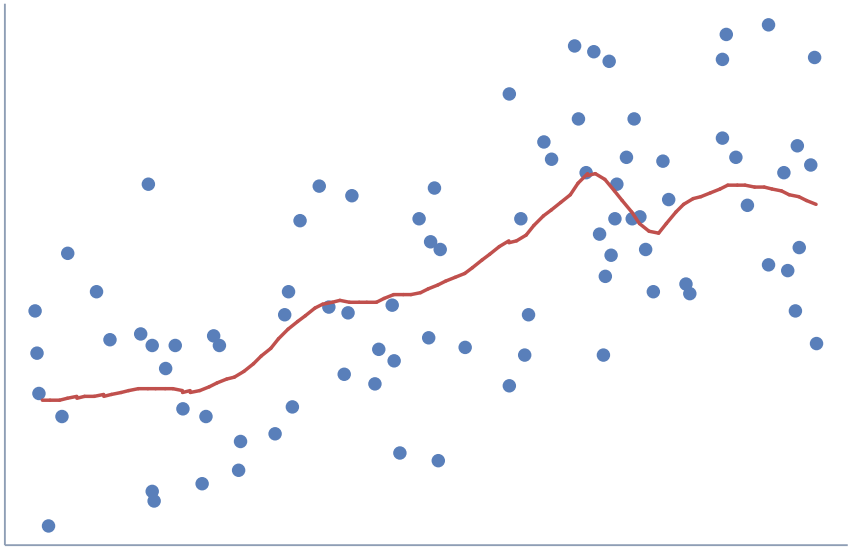
Introducción

- El modelo lineal, a pesar de su simpleza, puede ser una buena aproximación en un gran abanico de situaciones
- Otros modelos tienden a realizar sobrestimaciones que después no se corroboran con nuevos datos

Modelo lineal

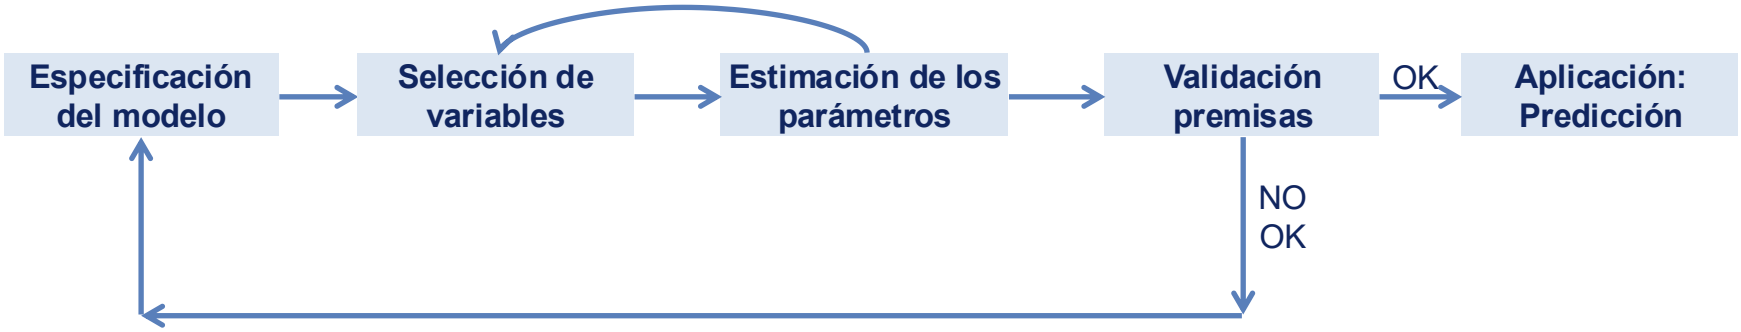


Modelo no paramétrico



Diseño de un modelo

Fases



- **Especificar:** definir qué respuesta explicar, qué predictores considerar, cómo relacionarlos y qué supuestos asumir sobre el error.
- **Estimar:** calcular con los datos los coeficientes del modelo definido.
- **Validar:** comprobar los supuestos antes de interpretar o predecir. Si fallan, revisar transformaciones, buscar otros predictores o plantear otro modelo.

Inferencia Estadística

Fases de estimación

02

laSalle ENG
Universitat Ramon Llull

Modelo lineal

Formulación

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_p X_{pi} + \varepsilon_i$$

$$\varepsilon_i \sim N(0, \sigma^2) \quad (k = 1, \ldots, p;\ i = 1, \ldots, n)$$

- Y_i: valor de la variable respuesta en el caso i-ésimo.
- X_{ki}: valor de la variable predictora k en el caso i-ésimo.
- β_0: término independiente (o intercepto).
  - β_k: coeficiente (pendiente) de la variable X_k (k = 1, …, p).
  - ε_i: error.
  - σ: desviación típica de los errores (desviación residual).
- Los parámetros a estimar del modelo son β_0, β_k y σ^2.
- El modelo lineal simple contiene únicamente una variable predictora.
- En las variables categóricas se estiman **tantos coeficientes como categorías menos uno**. Cada coeficiente mide el efecto respecto a una categoría de referencia (que se denomina contraste basal).

Modelo lineal

Estimación de los parámetros

β_0, β_k y σ^2 son parámetros poblacionales desconocidos. Al estimar los coeficientes β obtenemos la recta o el hiperplano ajustado:

$$\hat{y}_i = b_0 + b_1 X_{1i} + \cdots + b_p X_{pi}$$

Cada observación tiene un residuo: la diferencia entre su valor observado y la predicción del modelo.

$$e_i = y_i - \hat{y}_i$$

La estimación **por mínimos cuadrados** (la que veremos/utilizaremos) elige los coeficientes que minimizan la suma de los residuos al cuadrado. En el caso simple:

$$\sum_{i=1}^{n} {e_i}^2 = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 = \sum_{i=1}^{n} (y_i - b_0 - b_1 x_i)^2$$

Al elevar al cuadrado, los signos no se cancelan y los errores grandes pesan más.
Buscamos el mejor ajuste conjunto, no que cada residuo sea cero.

Modelo lineal

Significado de los coeficientes

Regresión lineal múltiple: estimamos la dureza del hormigón a partir de su composición y edad. Buscamos cuánto cambia la dureza con cada predictor, manteniendo los demás constantes.

Implementación

```
> modelo = sm.OLS(y_train, X_train).fit()
> print(modelo.summary())
```

	coef	std err	t	P>|t|
const	-18.78742	45.34568	-0.414	0.678925
Cement	0.11391	0.01466	7.772	1.11e-13
BlastFurnaceSlag	0.10193	0.01793	5.683	3.01e-08
FlyAsh	0.08609	0.02235	3.852	0.000142
Water	-0.16940	0.06732	-2.517	0.012349
Superplasticizer	0.20413	0.16432	1.242	0.215076
CoarseAggregate	0.01583	0.01645	0.962	0.336727
FineAggregate	0.02437	0.01895	1.286	0.199477
Age	0.12058	0.01048	11.507	< 2e-16

```
R-squared: 0.5973     Adj. R-squared: 0.5871
F-statistic: 58.41    Prob (F-statistic): < 2.2e-16
Df Model: 8           Df Residuals: 315
Desviación residual del ajuste original: 11.08
```

Intercepto: **−18,78742**
Con todo a 0, dureza = −18,8. Esa mezcla no tiene sentido físico.

Cement: **+0,11391**
Cada kg más se asocia con +0,114 de dureza, con el resto constante.

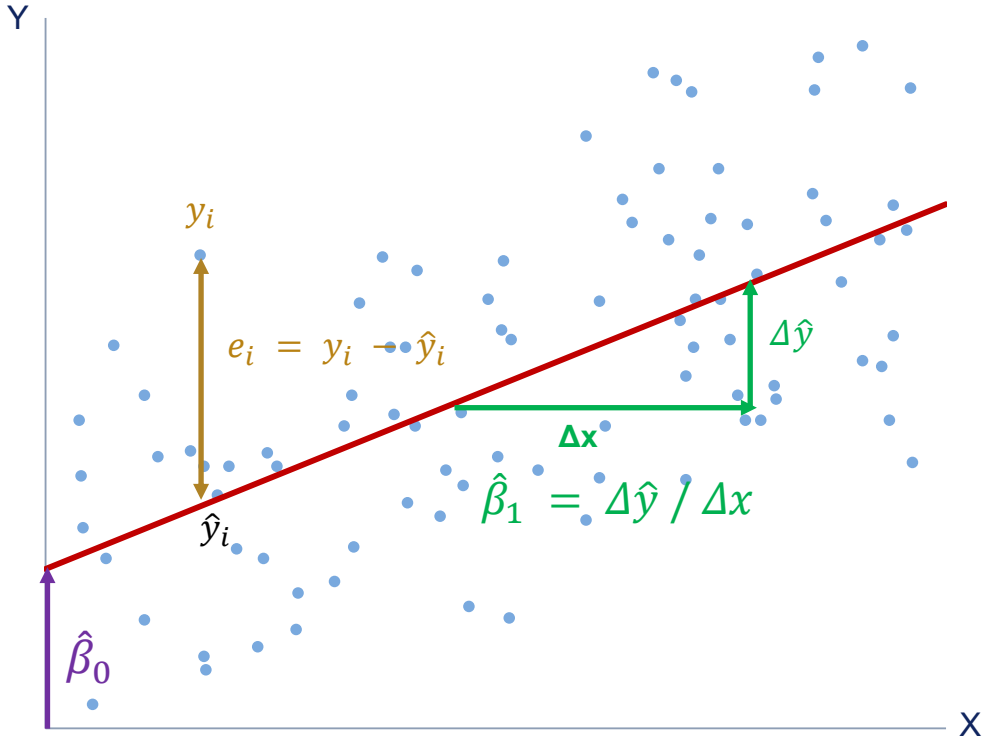
Water: **−0,16940**
Por cada 10 litros más: −1,694 de dureza, con el resto constante.

Modelo lineal

Interpretación de los coeficientes

- β_0 representa el valor esperado de la respuesta cuando todos los predictores valen cero.
- Si X_1 es continua, β_1 es el cambio esperado en la respuesta por cada unidad más de X_1, con los demás predictores constantes.
- Si X_1 es categórica, cada coeficiente compara una categoría con la de referencia, con los demás predictores constantes.
- En la recta estimada, $e_i = y_i - \hat{y}_i$ es el residuo. El error teórico ε_i mide la distancia a la media poblacional.

Regresión simple: $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$



Selección de variables

Concepto: Capacidad explicativa/Bondad de Ajuste

- R^2 indica qué proporción de la variabilidad de Y explica el modelo en la muestra de ajuste, frente a predecir siempre la media.

En mínimos cuadrados con intercepto: total = explicada + residual

$$\sum_i (y_i - \bar{y})^2 = \sum_i (\hat{y}_i - \bar{y})^2 + \sum_i (y_i - \hat{y}_i)^2$$

Total: datos respecto a la media | Explicada: ajuste respecto a la media | Residual: datos respecto al ajuste

$$R^2 = \frac{Explicada}{Total} = 1 - \frac{Residual}{Total}$$

- R^2 = 0,5973: el modelo explica el 59,73 % de la variabilidad. El 40,27 % queda en los residuos.

R^2 ajustado = 0,5871: penaliza añadir predictores y ayuda a comparar modelos con distinta complejidad.

Implementación

```
> print(modelo.rsquared)          0.5973
> print(modelo.rsquared_adj)      0.5871
```

- Con intercepto, $0 \leq R^2 \leq 1$ en el ajuste. Un R^2 alto no garantiza buenos resultados en datos nuevos: evalúa en test, donde R^2 puede ser negativo si el modelo supera el error de predecir su media.

Selección de variables

Concepto: Colinealidad y VIF

- **Información compartida.** Predictores muy relacionados aportan información redundante. Esto dificulta separar la asociación de cada uno con la respuesta.
- **Qué mide el VIF.** Resume la colinealidad del predictor j con el conjunto de los demás predictores.

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2}$$

- **Cómo obtenemos R^2_j.** Ajustamos una regresión auxiliar: X_j es la respuesta y los demás predictores son sus explicativas. **No incluimos la respuesta Y del modelo original.**
- **Cómo interpretarlo.** Con intercepto, R^2_j va de 0 a 1. Cuanto más se acerca a 1, mejor explican los demás a X_j y mayor es su VIF.
- **Umbral orientativo.** VIF = 5 equivale a $R^2_j = 0{,}80$: los demás explican el 80 % de la variabilidad de X_j. VIF > 5 pide revisar, no eliminar automáticamente.
- **Consecuencia.** La colinealidad aumenta los errores estándar y reduce la precisión de los coeficientes estimados.

Selección de variables

Concepto: Colinealidad y VIF, ejemplo en Python

- Varios predictores pueden aportar información parecida. Esto dificulta separar sus asociaciones con la variable respuesta.

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2}$$

Implementación

```
> from statsmodels.stats.outliers_influence import (
>     variance_inflation_factor)
> X = modelo.model.exog
> vif = pd.Series(
>     [variance_inflation_factor(X, j)
>      for j in range(1, X.shape[1])],
>     index=modelo.model.exog_names[1:])
> print(vif)
```

```
Cement              3.12
BlastFurnaceSlag    2.48
FlyAsh              2.76
Water               5.34
Superplasticizer    4.21
CoarseAggregate     1.85
FineAggregate       2.09
Age                 1.14
dtype: float64
```

$$\mathrm{VIF}_j > 5 \quad \mathrm{VIF}_j = 5 \Leftrightarrow R_j^2 = 0{,}80$$

R^2_j mide el ajuste de un predictor con los demás. La colinealidad aumenta la incertidumbre. Un VIF alto pide revisión, no borrado automático.

Selección de variables

Métodos automáticos

La selección automática compara modelos mediante AIC (criterio de Akaike) o BIC (criterio bayesiano). Un valor menor indica una mejor comparación relativa.

$$\text{AIC} = 2k - 2\log(L) \quad \text{BIC} = k\log(n) - 2\log(L)$$

k es el número de parámetros, n el tamaño muestral y L la verosimilitud maximizada. Ambos criterios equilibran ajuste y complejidad.

AIC y BIC favorecen modelos parsimoniosos.

Forward: parte del modelo sin predictores y añade, en cada paso, la variable que más mejora (más minimiza) el AIC o BIC.

Backward: parte del modelo completo y elimina, en cada paso, la variable cuya retirada más mejora (más minimiza) el criterio.

Forward-backward: combina pasos de incorporación y eliminación de variables.

LASSO/RIDGE: son otras alternativas basadas en penalización de coeficientes. No se desarrolla en este bloque.

Selección de variables

Metodología manual

1. Cribado inicial. Ajustar cada predictor por separado y preseleccionar los que tengan $p < 0{,}10$. Conservar también las variables relevantes por criterio técnico.

2. Modelo conjunto. Ajustar una regresión múltiple con las variables seleccionadas, usando los datos de entrenamiento.

3. Retirada de variables. Evaluar una a una las variables con $p > 0{,}05$, empezando por el mayor p-valor. Antes de retirar cada candidata:

a) Comparar los modelos. Usar el R^2 ajustado, que penaliza añadir predictores. Considerar la retirada si se mantiene o aumenta, con las mismas observaciones.

b) Revisar los coeficientes. Si alguno de los demás cambia más de un 10 %, conservar la candidata y estudiar posible confusión. El 10 % es orientativo.

c) Revisar la colinealidad. Un VIF > 5 alerta de información compartida. Revisar las variables implicadas, sin eliminar ninguna automáticamente.

4. Repetir y cerrar. Reajustar tras cada retirada y revisar el resto de candidatas. Comparar la predicción en validación y fijar el modelo antes de evaluar test.

Modelo lineal

Ejemplo: incertidumbre y selección de variables

Implementación

```
> modelo = sm.OLS(y_train, X_train).fit()
> print(modelo.summary())
```

```
                      coef    std err          t      P>|t|
const           -18.78742   45.34568   -0.414   0.678925
Cement            0.11391    0.01466    7.772   1.11e-13
BlastFurnaceSlag  0.10193    0.01793    5.683   3.01e-08
FlyAsh            0.08609    0.02235    3.852   0.000142
Water            -0.16940    0.06732   -2.517   0.012349
Superplasticizer  0.20413    0.16432    1.242   0.215076
CoarseAggregate   0.01583    0.01645    0.962   0.336727
FineAggregate     0.02437    0.01895    1.286   0.199477
Age               0.12058    0.01048   11.507    < 2e-16

R-squared: 0.5973     Adj. R-squared: 0.5871
F-statistic: 58.41    Prob (F-statistic): < 2.2e-16
Df Model: 8          Df Residuals: 315
Desviación residual del ajuste original: 11.08
```

Cement: +0,11391 en la respuesta por unidad más, con el resto constante.

$p = 1{,}11 \times 10^{-13}$: evidencia contra H_0: $\beta = 0$, dado el resto de predictores.

Error estándar: 0,01466. Mide la incertidumbre del coeficiente estimado.

$R^2 = 0{,}5973$: explica el 59,73% de la variabilidad en la muestra de ajuste.

Desviación residual/Error típico: 11,08. Estima la dispersión de los errores del modelo.

Validación

Supuestos para interpretar y predecir

- **Linealidad:** La media de Y sigue la **combinación lineal** de predictores propuesta. Una curva en los residuos sugiere revisar esa forma.

$$E(Y_i \mid X) = \beta_0 + \sum_{k=1}^{p} \beta_k X_{ki}$$

- **Error medio nulo:** Sin sesgo sistemático.

$$E(\varepsilon_i \mid X) = 0$$

- **Homoscedasticidad**: La varianza del error es constante para cualquier X.

$$Var(\varepsilon_i \mid X) = \sigma^2$$

- **Independencia:** Conocer el error de una observación no aporta información sobre el de otra.

$$\varepsilon_i \perp \varepsilon_j \mid X, \qquad i \neq j$$

- **Sin colinealidad perfecta:** Ningún predictor se obtiene exactamente a partir de los demás. Así podemos identificar sus coeficientes.

$$rank(X) = p + 1$$

- **Normalidad:** Los errores siguen una distribución normal. Permite la inferencia clásica exacta en muestras pequeñas.

$$\varepsilon_i \mid X \sim N(0, \sigma^2)$$

BLUE: estimador lineal insesgado de menor varianza, bajo los supuestos de Gauss–Markov. No requiere normalidad.

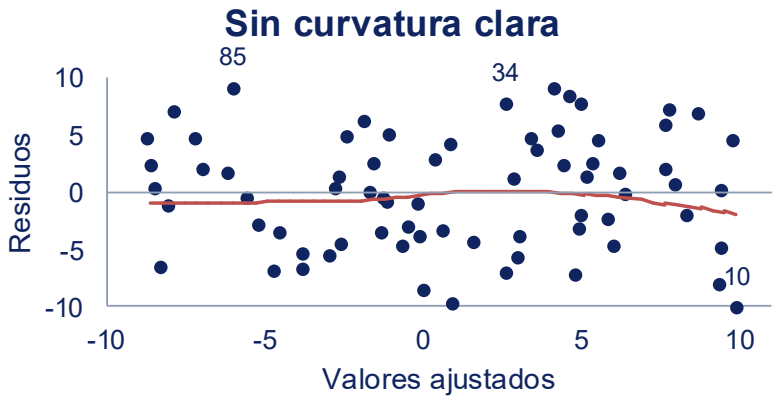
Validación

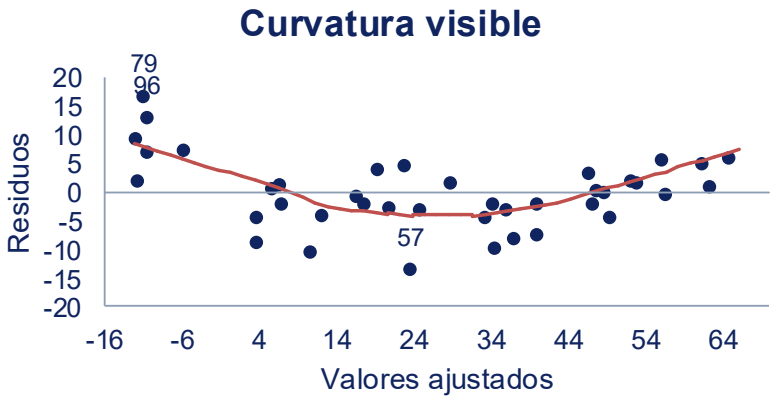
Premisas - Linealidad

- El residuo es el valor observado menos el predicho. En mínimos cuadrados con intercepto, la media de los residuos es 0.
- Una curva persistente indica que el modelo deja una relación sin recoger.

Implementación

```
> plt.scatter(modelo.fittedvalues, modelo.resid)
> plt.show()
```



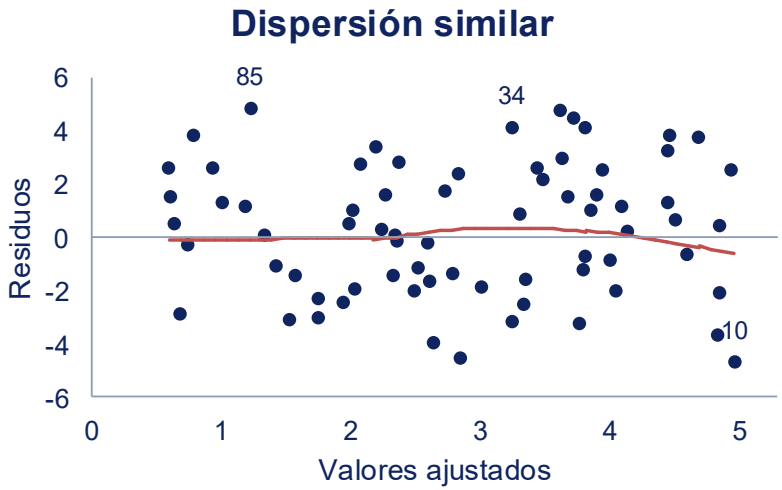


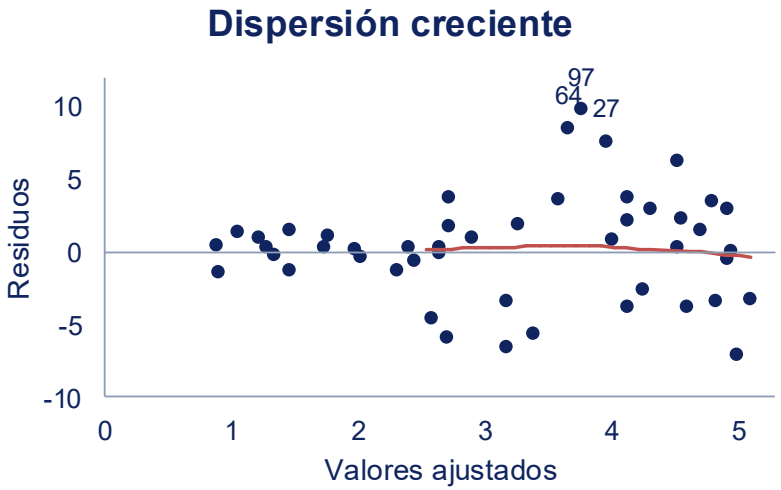
Si aparece curvatura: revisar transformaciones o términos adicionales y volver a comprobar los residuos.

Validación

Premisas - Homoscedasticidad

- Homoscedasticidad significa que la variabilidad del error se mantiene constante. En el gráfico, buscamos una amplitud vertical similar.
- Un abanico o embudo sugiere heteroscedasticidad: la precisión cambia según el nivel de la respuesta.





Si cambia la varianza: revisar la especificación y considerar errores estándar robustos para la inferencia.

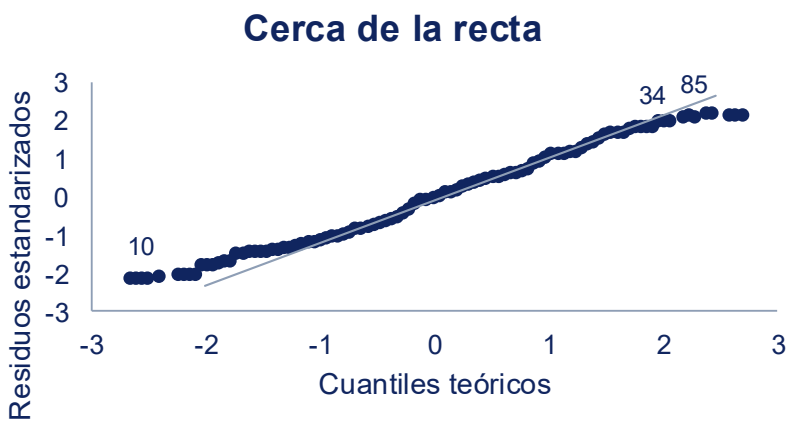
Validación

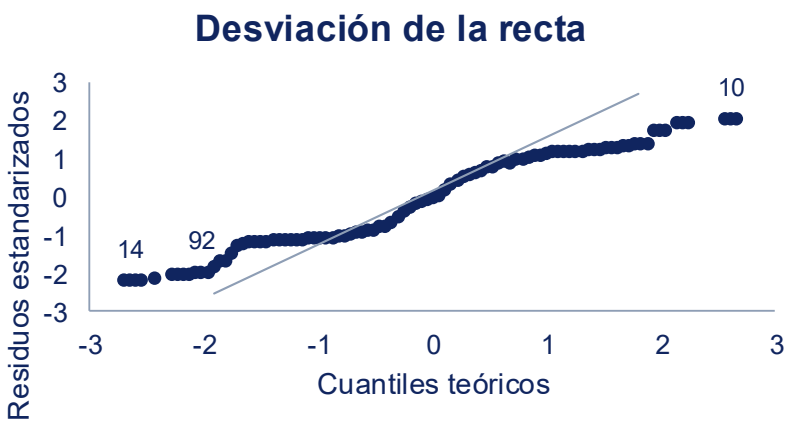
Premisas – Normalidad de los errores

- El Q–Q compara los cuantiles de los residuos con los de una normal. Puntos próximos a la recta son compatibles con normalidad.
- Desviaciones sistemáticas, sobre todo en los extremos, sugieren asimetría o colas distintas.

Implementación

```
› sm.qqplot(modelo.resid, line="s")
› plt.show()
```





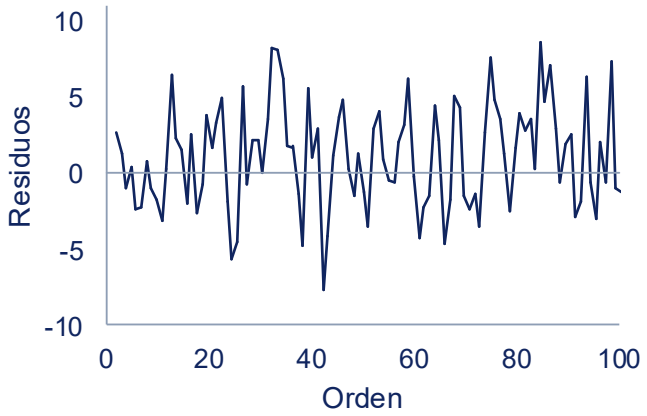
Si hay desviaciones: revisar casos extremos y la forma del modelo. No exigimos que Y ni los predictores sean normales.

Validación

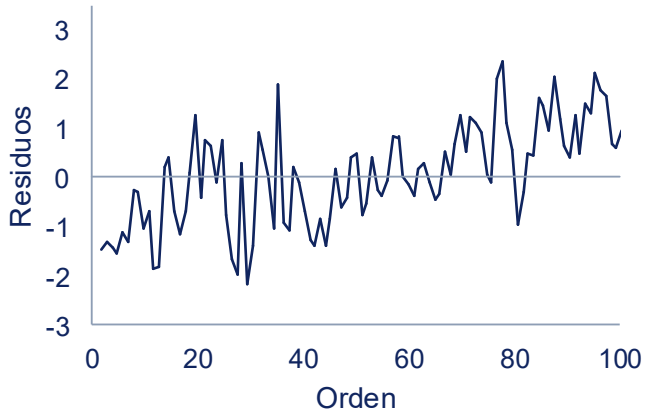
Premisas – Independencia

- Los errores pueden estar relacionados entre observaciones cercanas en el tiempo o del mismo grupo. Un orden arbitrario de filas no permite detectarlo.
- Con el orden temporal real, buscamos rachas, ciclos o tendencias en los residuos.

Sin patrón claro



Tendencia temporal



Una tendencia como esta sugiere estructura temporal que el modelo no recoge.

Si hay dependencia: modelar su estructura y separar grupos o periodos al evaluar la predicción.

Validación

Transformaciones

Los patrones de los residuos orientan la transformación. Cambiar Y puede estabilizar la varianza y mejorar la normalidad de los errores. Cambiar X puede corregir curvatura.

VARIABLE RESPUESTA: cambiamos la escala de Y

Logaritmo, si Y > 0. Comprime valores altos. Puede ayudar cuando la dispersión de los residuos aumenta con el nivel de la respuesta.

$$Y' = log(Y) = \beta_0 + \beta_1 X + \varepsilon$$

Box–Cox, si Y > 0. Familia de transformaciones controlada por λ. Incluye el logaritmo cuando λ = 0.

$$Y^{(\lambda)} = \begin{cases} \dfrac{Y^{\lambda} - 1}{\lambda} & si\ \lambda \neq 0 \\ log(Y) & si\ \lambda = 0 \end{cases}$$

Elegimos λ con entrenamiento y revisamos los residuos del modelo completo. Box–Cox no garantiza resolver todos los problemas.

VARIABLES PREDICTORAS: cambiamos la forma de la relación

Representamos los residuos frente a cada X. Si aparece curvatura, probamos una transformación adecuada, como log(X) para X > 0, y reajustamos el modelo completo.

Validación

Transformaciones: ejemplo en Python

- Una transformación cambia la forma de la relación. En este ejemplo, log(Age) permite que el cambio en la respuesta por un año adicional dependa de la edad.

Implementación

```
> import numpy as np
> X_log = X_train.copy()
> X_log["Age"] = np.log(train["Age"])
> modelo_log = sm.OLS(y_train, X_log).fit()
> print(modelo_log.summary())
```

```
Salida simulada (extracto)
OLS Regression Results
No. Observations: 80
R-squared:       0.720
Adj. R-squared:  0.688
Df Residuals:       71
F-statistic:     22.82
```

- log(Age) exige valores positivos. La respuesta conserva su escala, pero el coeficiente ahora multiplica al logaritmo de Age.
- Box–Cox transforma la respuesta positiva mediante λ. Estimar λ solo con entrenamiento y revisar de nuevo los residuos.
- Comparar candidatos dentro de train, sin usar test. Si transformamos Y, deshacer la transformación exige cuidar el sesgo y los intervalos.

Validación

Observaciones influyentes: distancia de Cook

- **Influencia.** Un caso puede condicionar el ajuste. Al retirarlo y reajustar, pueden cambiar mucho los coeficientes y las predicciones.
- **Residuo.** Mide cuánto se aleja la observación de la predicción del modelo.
- **Leverage.** Mide lo inusual de sus valores de X respecto al resto. Un leverage alto, por sí solo, no implica influencia.

$$D_i = \frac{\sum_{j=1}^{n} (\hat{y}_j - \hat{y}_{j(i)})^2}{(k+1)\,\hat{\sigma}^2}$$

Cook suma los cambios al cuadrado en las predicciones de todos los casos y los normaliza por el número de coeficientes y la varianza residual.

$\hat{y}_j$. Predicción del modelo completo para el caso j.

$\hat{y}_{j(i)}$. Predicción para ese mismo caso j tras ajustar sin el caso i.

k + 1. Coeficientes, incluido el intercepto.

$\hat{\sigma}^2$. Varianza residual del modelo completo.

n. Número de observaciones del ajuste.

Validación

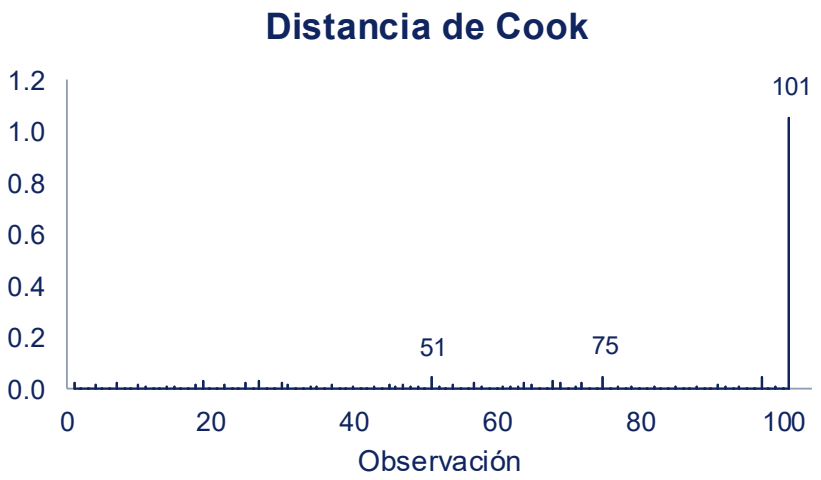
Observaciones influyentes: detección y revisión

Implementación

```
> cook = modelo.get_influence().cooks_distance[0]
> casos = train.loc[cook > 4 / len(train)]
> print(casos.index.tolist())
```

$$D_i > \frac{4}{n}$$

4/n es una referencia orientativa. Un valor alto señala un caso que conviene investigar, no una orden de eliminarlo.



El gráfico simulado señala los casos 51, 75 y 101. El 101 destaca por su distancia de Cook.

Reajustar sin los casos señalados y comparar las conclusiones. Verificar errores y contexto antes de excluir datos válidos.

Inferencia Estadística

Predicción

03

laSalle ENG
Universitat Ramon Llull

Modelo lineal

Predicción: valor individual y valor esperado

Con los mismos valores de los predictores, podemos plantear dos objetivos.

Valor individual: una observación concreta

Predecimos el retraso de un vuelo concreto. El intervalo de predicción incluye la incertidumbre de la media y la variación entre vuelos.

Ejemplo: ¿qué retraso tendrá el vuelo BCN–ROM de Vueling de las 8:00?

Valor esperado: el promedio de observaciones iguales en X

Estimamos el retraso promedio de vuelos con los mismos predictores. El intervalo de confianza cuantifica la incertidumbre de esa media.

Ejemplo: ¿cuál es el retraso medio de los vuelos BCN–ROM de Vueling a las 8:00?

La estimación puntual es la misma en ambos casos

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_{01} + \cdots + \hat{\beta}_p x_{0p}$$

"Puntual" significa un único número. El intervalo de predicción es más amplio porque una observación puede alejarse de la media, aun con los mismos X.

Modelo lineal

Ejemplo de vuelos: predicción en Python

Implementación

```
> import pandas as pd
> import statsmodels.formula.api as smf
> f = "retraso ~ C(ruta) + C(compania) + hora"
> modelo_v = smf.ols(f, data=train_vuelos).fit()
> nuevo = pd.DataFrame({"ruta": ["BCN-ROM"],
>     "compania": ["Vueling"], "hora": [8]})
> pred = modelo_v.get_prediction(nuevo).summary_frame(alpha=0.05)
```

Un vuelo concreto

Intervalo de predicción del 95 % para el retraso de una observación nueva.

Implementación

```
> cols = ["mean", "obs_ci_lower",
>         "obs_ci_upper"]
> print(pred[cols])
       mean  obs_ci_lower  obs_ci_upper
0  12.957354     -6.599553     32.514262
```

Promedio de vuelos iguales en X

Intervalo de confianza del 95 % para el retraso medio de esos vuelos.

Implementación

```
> cols = ["mean", "mean_ci_lower",
>         "mean_ci_upper"]
> print(pred[cols])
       mean  mean_ci_lower  mean_ci_upper
0  12.957354      10.198012      15.716697
```

Inferencia Estadística

Evaluación

03

laSalle ENG
Universitat Ramon Llull

Capacidad predictiva

Separación de entrenamiento y test

Antes de ajustar el modelo, separamos los datos: aprendemos con train y reservamos test para estimar cómo predecirá en observaciones nuevas.

TRAIN · 80 observaciones (80 %)	TEST 20 (20 %)

TRAIN: desarrollar el modelo

Ajustar coeficientes, elegir variables y transformaciones. Comparar alternativas con validación dentro de train.

TEST: evaluación final

Aplicar el modelo ya fijado y medir sus errores. No usar estos resultados para elegir o retocar el modelo.

Implementación

```
› from sklearn.model_selection import (
›     train_test_split)
› train, test = train_test_split(
›     datos, test_size=0.20, random_state=42)
› print(len(train), len(test))
80 20
```

Capacidad predictiva

Interpretación de las métricas

Raíz del error cuadrático medio (RMSE):

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

Error absoluto medio (MAE):

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

Error porcentual absoluto medio (MAPE):

$$\mathrm{MAPE} = \frac{100}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right|$$

Coeficiente de determinación en test:

$$R^2_{\mathrm{test}} = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

RMSE penaliza más los errores grandes. MAE resume el error absoluto medio. Ambos usan las unidades de la respuesta.

y_i: valor observado · $\hat{y}_i$: predicción · n: casos de test · $\bar{y}$: media observada en test

MAPE expresa error porcentual, pero no está definido con valores observados iguales a cero y es inestable cerca de cero. R^2 de test puede ser negativo.

Capacidad predictiva

Ejemplo en Python: evaluación en test

- Evaluamos la tercera pregunta con el test reservado. El modelo debe quedar fijado antes de mirar sus errores.

Implementación

```
> y_test = test["Strength"]
> y_pred = modelo.predict(X_test)
> rmse = np.sqrt(mean_squared_error(y_test, y_pred))
> mae = mean_absolute_error(y_test, y_pred)
> r2 = r2_score(y_test, y_pred)
> print({"RMSE": rmse, "MAE": mae, "R2": r2})

{'RMSE': 10.42, 'MAE': 8.16, 'R2': 0.61}
```

- RMSE y MAE se expresan en las unidades de Strength. Un valor menor indica errores más pequeños.
- La comparación con modelos alternativos ocurre antes, mediante validación dentro de train. Test estima el rendimiento final.

Anexo: derivaciones

Regresión lineal: mínimos cuadrados y máxima verosimilitud

Material de ampliación · MUBD

laSalle ENG
Universitat Ramon Llull

Anexo: Modelo lineal

Caso simple: derivadas y primera ecuación normal

1. Minimizamos la suma de cuadrados. Todas las sumas van de i = 1 a n.

$$S(b_0, b_1) = \sum(y_i - b_0 - b_1 x_i)^2$$

2. Aplicamos la regla de la cadena e igualamos las derivadas a cero.

$$\frac{\partial S}{\partial b_0} = -2\sum(y_i - b_0 - b_1 x_i) = 0$$

$$\frac{\partial S}{\partial b_1} = -2\sum x_i(y_i - b_0 - b_1 x_i) = 0$$

3. En la primera ecuación, abrimos la suma y dividimos por n.

$$\sum y_i - n b_0 - b_1 \sum x_i = 0$$

$$\bar{y} - b_0 - b_1 \bar{x} = 0 \Rightarrow b_0 = \bar{y} - b_1 \bar{x}$$

Anexo: Modelo lineal

Caso simple: sustitución y despeje de la pendiente

4. Sustituimos $b_0 = \bar{y} - b_1\bar{x}$ en la segunda ecuación normal.

$$\sum x_i[y_i - \bar{y} - b_1(x_i - \bar{x})] = 0$$

5. Escribimos $x_i = (x_i - \bar{x}) + \bar{x}$. Las sumas de desviaciones son cero.

$$\sum(x_i - \bar{x})(y_i - \bar{y}) - b_1\sum(x_i - \bar{x})^2 = 0$$

6. Aislamos b_1 y recuperamos el intercepto.

$$b_1 = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2}$$

$$b_0 = \bar{y} - b_1\bar{x}$$

Si x varía, el denominador es positivo y el mínimo es único. La recta ajustada pasa por el punto $(\bar{x}, \bar{y})$.

Anexo: Modelo lineal

Caso múltiple: verosimilitud del modelo normal

1. Suponemos errores normales independientes con varianza común. X incluye una columna de unos y p predictores.

$$y = X\beta + \varepsilon \quad \varepsilon \mid X \sim N(0, \sigma^2 I)$$

2. Por independencia, multiplicamos las densidades de las observaciones.

$$L(\beta, \sigma^2 \mid y, X) = (2\pi\sigma^2)^{-n/2} \, exp[-\frac{(y - X\beta)^T (y - X\beta)}{2\sigma^2}]$$

3. Tomamos logaritmos para convertir el producto en una suma.

$$\ell(\beta, \sigma^2) = -\frac{n}{2} log(2\pi\sigma^2) - \frac{(y - X\beta)^T (y - X\beta)}{2\sigma^2}$$

Para σ² fija, maximizar ℓ respecto a β equivale a minimizar la suma de cuadrados. La normalidad conecta ambos métodos.

Anexo: Modelo lineal

Caso múltiple: máximo y ecuaciones normales

4. Derivamos la log-verosimilitud respecto al vector β.

$$\frac{\partial \ell}{\partial \beta} = \frac{1}{\sigma^2} X^T (y - X\beta)$$

5. Igualamos a cero y obtenemos las mismas ecuaciones normales.

$$X^T y - X^T X\hat{\beta} = 0 \Rightarrow X^T X\hat{\beta} = X^T y$$

6. Con rango completo de columnas, despejamos el estimador.

$$\hat{\beta}_{MV} = (X^T X)^{-1} X^T y = \hat{\beta}_{MCO}$$

La Hessiana es negativa definida con rango completo: el máximo es único.

$$\frac{\partial^2 \ell}{\partial \beta \partial \beta^T} = -\frac{1}{\sigma^2} X^T X$$

Anexo: Modelo lineal

Intervalos: media y observación nueva

Mismos predictores x_0, misma estimación puntual: $\hat{y}_0 = x_0^T \hat{\beta}$

Media de la respuesta

$$\hat{y}_0 \pm t^* \, s \, \sqrt{(h_0)}$$

Incertidumbre al estimar el promedio para esos predictores.

Observación nueva

$$\hat{y}_0 \pm t^* \, s \, \sqrt{(1 + h_0)}$$

Añade la variación individual: el +1 ensancha el intervalo.

$$\mathbf{SE^2(predicción) = SE^2(media) + s^2}$$

$$h_0 = x_0^T (X^T X)^{-1} x_0$$

X y x_0 incluyen el intercepto. h_0 depende del punto y del diseño de entrenamiento.

$$s^2 = \Sigma_{i=1}^{n} (y_i - \hat{y}_i)^2 \, / \, (n - p - 1)$$

p: número de predictores. n: observaciones. s^2 estima la varianza residual.

$t^* = t_{1-\alpha/2,\, n-p-1}$ es el cuantil de Student. Para el 95 %, $\alpha = 0{,}05$.

OLS con rango completo, errores normales independientes y varianza constante. Caso nuevo independiente.

MUBD

Màster Universitari en Enginyeria de Dades Massives (Big Data)

Estadística

laSalle ENG
Universitat Ramon Llull